

Segmentação Semântica de Nuvens de Pontos LiDAR

Uma Abordagem Híbrida Combinando Processamento Geométrico com Aprendizado Profundo

Matheus Leonel de Andrade¹

¹Instituto de Informática
Universidade Federal de Goiás

2025

Roteiro



1. Introdução
2. Fundamentação Teórica
3. Metodologia
4. Resultados
5. Conclusão e Trabalhos Futuros



Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).
- Sensores LiDAR (Light Detection and Ranging) são essenciais, fornecendo nuvens de pontos 3D densas e precisas.
- **Desafio:** Processar e interpretar o grande volume de dados das nuvens de pontos (alta dimensionalidade, esparsas, desordenadas) de forma eficiente.



Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam alta acurácia, mas exigem alto custo computacional, dificultando o uso em sistemas com recursos limitados.
- A segmentação do solo e a clusterização de objetos são etapas críticas e desafiadoras.



Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline eficiente para segmentação e classificação semântica de nuvens de pontos LiDAR.
- **Abordagem Híbrida:** Combinar a eficiência de métodos clássicos de processamento geométrico com o poder de generalização de técnicas de aprendizado profundo.
- **Hipótese:** Investigar se a redução da dimensionalidade, através da clusterização, preserva informação semântica suficiente para uma classificação eficaz, equilibrando acurácia e custo computacional.

Conceitos Fundamentais

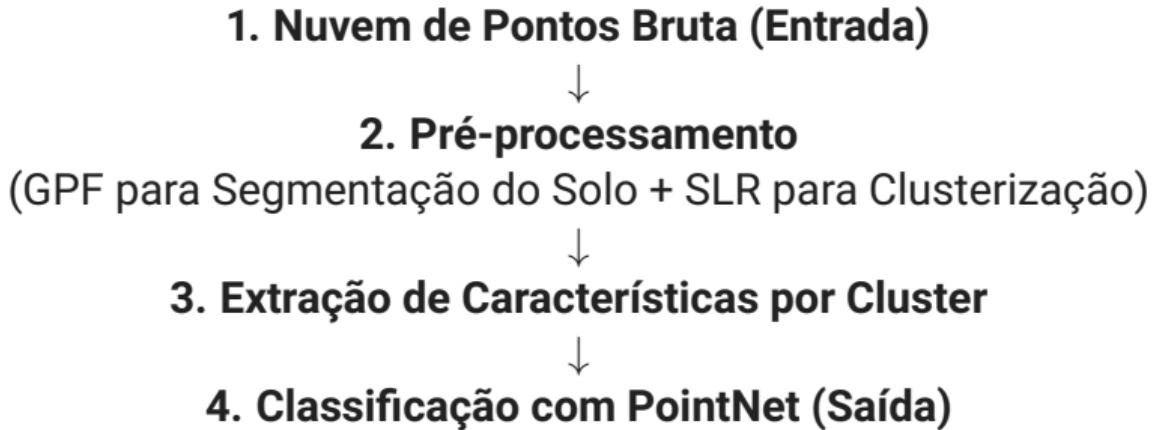
Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.
- LiDAR gera padrão de "scanlines".

Segmentação e Clusterização

- **Segmentação:** Atribuir um rótulo semântico a cada ponto (e.g., solo, carro, prédio).
- **Clusterização:** Agrupar pontos próximos que pertencem ao mesmo objeto físico.

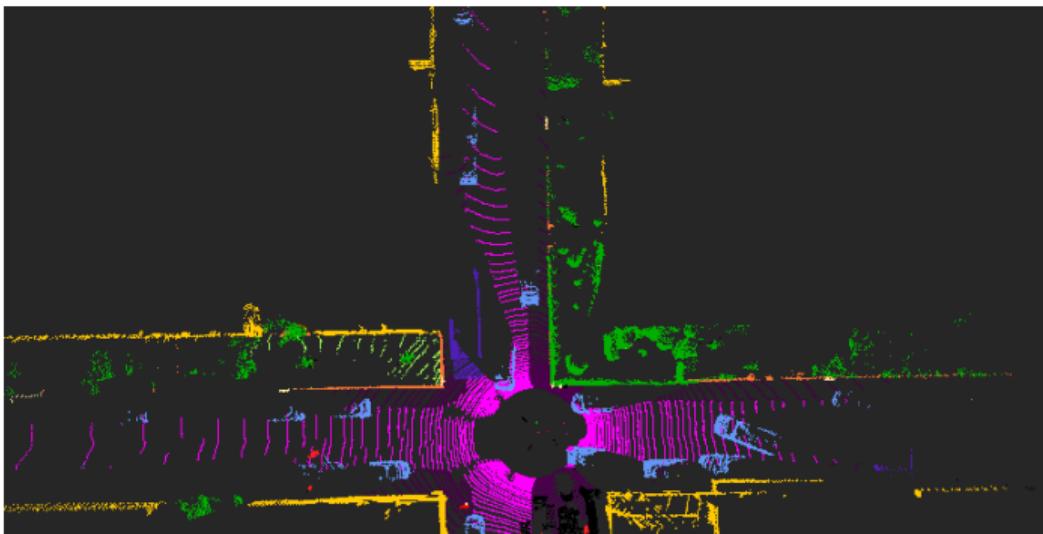
Pipeline Proposto





Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em condução autônoma.
- Extensão semântica do KITTI Vision Benchmark.
- Fornece anotações semânticas densas para nuvens de pontos capturadas por um LiDAR Velodyne HDL-64E.
- Foco do trabalho em 20 classes semânticas relevantes para navegação.





Pré-processamento: Segmentação do Solo (GPF)

- **Objetivo:** Identificar e remover os pontos pertencentes ao solo.
- **Algoritmo:** Ground Plane Fitting (GPF).
- **Como funciona:**
 1. A nuvem de pontos é dividida em setores angulares.
 2. Em cada setor, o solo é modelado como um plano.
 3. O plano é estimado de forma iterativa usando SVD (Decomposição de Valores Singulares) sobre os pontos de menor altura.
 4. Pontos próximos ao plano estimado são classificados como solo.



Pré-processamento: Clusterização de Objetos (SLR)

- **Objetivo:** Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.
- **Algoritmo:** Scan Line Run (SLR).
- **Como funciona:**
 1. Explora a estrutura sequencial das linhas de varredura (scanlines) do LiDAR.
 2. Pontos em uma mesma scanline são agrupados com base na proximidade.
 3. Clusters de scanlines adjacentes são fundidos se estiverem próximos.
 4. Resultado: Uma lista de clusters, cada um representando um potencial objeto.

Avaliação do Pré-processamento



Redução de Dimensionalidade

- O pipeline reduziu o número de pontos em **98,84%**.
- Transforma uma nuvem com ~ 120.000 pontos em ~ 1.400 clusters.
- Redução massiva do custo computacional para a etapa de classificação.

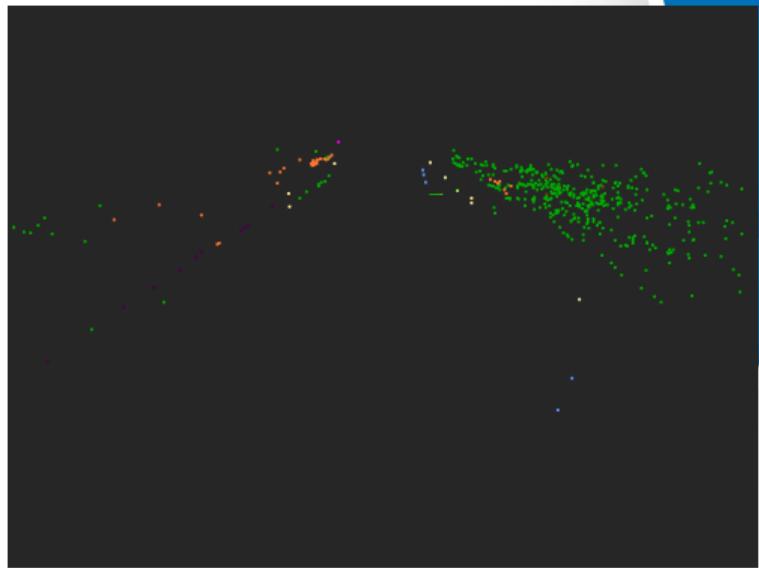


Figure 2: Clusters (cores aleatórias).

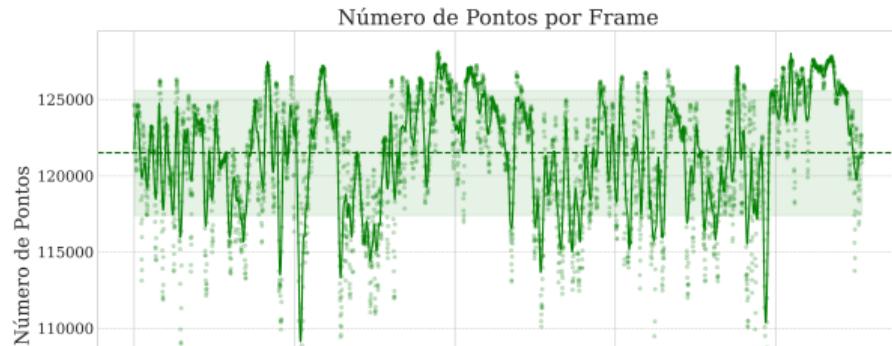
Consistência Semântica

- **95%** dos clusters gerados eram "semanticamente puros"



Resultados da Classificação

- Após o pré-processamento, um vetor de características foi extraído para cada cluster.
- Uma rede PointNet simplificada foi usada para classificar cada cluster.
- **Acurácia de Classificação:** O modelo alcançou **93,27%** de acurácia na classificação dos clusters.
- **Conclusão:** A representação compacta em clusters, mesmo após uma redução de dados de >98%, reteve informação suficiente para uma classificação semântica de alta qualidade.





Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.
- A abordagem demonstrou um excelente equilíbrio entre eficiência computacional e acurácia.
- **Principal Contribuição:** Demonstração de que é possível comprimir drasticamente nuvens de pontos LiDAR em representações de clusters, preservando a informação semântica essencial para a classificação.
- Os resultados (redução de 98.8%, acurácia de 93.3%) confirmam a viabilidade da metodologia para aplicações que demandam eficiência.

Limitações e Trabalhos Futuros



Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).
- Enriquecer as características dos clusters (e.g., intensidade, contexto).
- Otimizar o pipeline para hardware embarcado.
- Validar em outras plataformas robóticas e com diferentes sensores.

Obrigado! Perguntas?

