

Segmentação Semântica de Nuvens de Pontos LiDAR

Uma Abordagem Híbrida Combinando Processamento Geométrico com Aprendizado Profundo

Matheus Leonel de Andrade¹

¹Instituto de Informática
Universidade Federal de Goiás

2025

Sumário



1. Introdução
2. Fundamentação Teórica
3. Metodologia
4. Resultados
5. Conclusão e Trabalhos Futuros



Introdução

Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).





Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).
- Nesse sentido os sensores LiDAR (Light Detection and Ranging) se destacam pois fornecem nuvens de pontos 3D, permitindo a análise detalhada da geometria do ambiente.



Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).
- Nesse sentido os sensores LiDAR (Light Detection and Ranging) se destacam pois fornecem nuvens de pontos 3D, permitindo a análise detalhada da geometria do ambiente.
- **Desafio:** Processar e interpretar o grande volume de dados das nuvens de pontos de forma eficiente, já que sensores LiDAR modernos podem capturar mais de 100.000 pontos por varredura.

Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.





Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam uma boa acurácia, mas exigem alto custo computacional.



Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam uma boa acurácia, mas exigem alto custo computacional.
- A segmentação do solo e a clusterização de objetos são etapas críticas e desafiadoras.



Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam uma boa acurácia, mas exigem alto custo computacional.
- A segmentação do solo e a clusterização de objetos são etapas críticas e desafiadoras.
 - A identificação do solo, serve como base para detecção de obstáculos, e planejamento de rotas, por exemplo.



Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam uma boa acurácia, mas exigem alto custo computacional.
- A segmentação do solo e a clusterização de objetos são etapas críticas e desafiadoras.
 - A identificação do solo, serve como base para detecção de obstáculos, e planejamento de rotas, por exemplo.
 - Da mesma forma, a clusterização e classificação de objetos, é fundamental para a tomada de decisões seguras em sistemas autônomo.



Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline para segmentação e classificação semântica de nuvens de pontos LiDAR.



Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline para segmentação e classificação semântica de nuvens de pontos LiDAR.
- **Abordagem Híbrida:** Combinar a eficiência de métodos clássicos de processamento geométrico com o poder de generalização de técnicas de aprendizado profundo.



Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline para segmentação e classificação semântica de nuvens de pontos LiDAR.
- **Abordagem Híbrida:** Combinar a eficiência de métodos clássicos de processamento geométrico com o poder de generalização de técnicas de aprendizado profundo.
- **Hipótese:** Investigar se a redução da dimensionalidade, através da clusterização, preserva informação semântica suficiente para uma classificação eficaz, equilibrando acurácia e custo computacional.



Fundamentação Teórica

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).

Segmentação e Clusterização

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.

Segmentação e Clusterização

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.

Segmentação e Clusterização

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.

Segmentação e Clusterização

- **Segmentação:** Atribuir um rótulo semântico a cada ponto (e.g., solo, carro, prédio).

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.

Segmentação e Clusterização

- **Segmentação:** Atribuir um rótulo semântico a cada ponto (e.g., solo, carro, prédio).
- **Clusterização:** Agrupar pontos próximos que pertencem ao mesmo objeto físico.

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)

Limitações Práticas

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância

Limitações Práticas

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Limitações Práticas

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Limitações Práticas

- Oclusões e dados incompletos

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Limitações Práticas

- Oclusões e dados incompletos
- Processamento em tempo real

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Limitações Práticas

- Oclusões e dados incompletos
- Processamento em tempo real
- Generalização entre ambientes

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes
- **PointNet** - Classificação Semântica:

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes
- **PointNet** - Classificação Semântica:
 - Processa coordenadas 3D diretamente (sem projeção)

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes
- **PointNet** - Classificação Semântica:
 - Processa coordenadas 3D diretamente (sem projeção)
 - Invariante a permutações

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes
- **PointNet** - Classificação Semântica:
 - Processa coordenadas 3D diretamente (sem projeção)
 - Invariante a permutações
 - T-Net para alinhamento espacial



Metodología

Pipeline Proposto



1. Nuvem de Pontos Bruta (Entrada)



2. Pré-processamento

2.1 GPF (Segmentação do Solo)



2.2 SLR (Clusterização)



2.3 Extração de Características



3. Classificação com PointNet (Saída)

Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em direção autônoma.



Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em direção autônoma.
- Extensão do KITTI Vision Benchmark.



Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em direção autônoma.
- Extensão do KITTI Vision Benchmark.
- Fornece anotações semânticas densas para nuvens de pontos capturadas por um LiDAR Velodyne HDL-64E.



Dataset: SemanticKITTI



- Benchmark de referência para percepção 3D em direção autônoma.
- Extensão do KITTI Vision Benchmark.
- Fornece anotações semânticas densas para nuvens de pontos capturadas por um LiDAR Velodyne HDL-64E.
- Foco do trabalho em 20 classes semânticas relevantes para navegação.

Dataset: SemanticKITTI

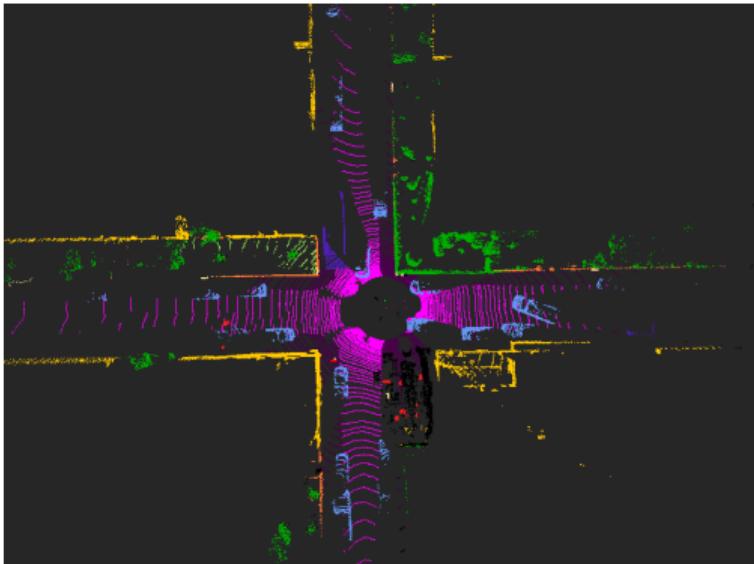


Figure 1: Exemplo de uma cena do SemanticKITTI com rótulos semânticos.
(sequencia 7 - frame 993)

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. Seleção dos pontos sementes.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. Seleção dos pontos sementes.
2. Estimativa do plano: calcula o LRP, em seguida aplica SVD para obter o vetor normal do plano.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. Seleção dos pontos sementes.
2. Estimativa do plano: calcula o LRP, em seguida aplica SVD para obter o vetor normal do plano.
3. Refinamento iterativo: inclui pontos próximos do plano (< limiar) em iterações sucessivas, e repete o item 2.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. Seleção dos pontos sementes.
2. Estimativa do plano: calcula o LRP, em seguida aplica SVD para obter o vetor normal do plano.
3. Refinamento iterativo: inclui pontos próximos do plano (< limiar) em iterações sucessivas, e repete o item 2.
4. Classificação final: pontos do solo recebem label específico.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.
2. Identificação de "runs": segmentos contínuos com distância < limiar.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.
2. Identificação de "runs": segmentos contínuos com distância < limiar.
3. Propagação de rótulos entre scanlines adjacentes (< limiar).

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.
2. Identificação de "runs": segmentos contínuos com distância < limiar.
3. Propagação de rótulos entre scanlines adjacentes (< limiar).
4. Resolução de equivalências via tabela para fundir rótulos duplicados.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.
2. Identificação de "runs": segmentos contínuos com distância < limiar.
3. Propagação de rótulos entre scanlines adjacentes (< limiar).
4. Resolução de equivalências via tabela para fundir rótulos duplicados.
5. Atribuição final: cada cluster recebe identificador único.

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)
 - Capturam forma e orientação do cluster

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)
 - Capturam forma e orientação do cluster
- Rótulos (2 valores):

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)
 - Capturam forma e orientação do cluster
- Rótulos (2 valores):
 - True label (anotação ground truth)

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)
 - Capturam forma e orientação do cluster
- Rótulos (2 valores):
 - True label (anotação ground truth)
 - Predicted label (placeholder para classificação)



Resultados

Avaliação do Pré-processamento



Redução de Dimensionalidade

O pipeline reduziu o número de pontos em **98,84%**.

Figure 2: <

4->Clusters (cores aleatórias).

Figure 3: <

4->Rótulos verdadeiros.

Consistência Semântica

95% dos clusters gerados eram "semanticamente puros".

Avaliação do Pré-processamento



Redução de Dimensionalidade

O pipeline reduziu o número de pontos em **98,84%**.

- Transforma uma nuvem com ~120.000 pontos em ~1.400 clusters.
- Redução massiva do custo computacional para a etapa de classificação.

Figure 2: <

4->Clusters (cores aleatórias).

Figure 3: <

4->Rótulos verdadeiros.

Consistência Semântica

95% dos clusters gerados eram "semanticamente puros".

Avaliação do Pré-processamento



Redução de Dimensionalidade

O pipeline reduziu o número de pontos em **98,84%**.

- Transforma uma nuvem com ~120.000 pontos em ~1.400 clusters.
- Redução massiva do custo computacional para a etapa de classificação.

Figure 2: <

4->Clusters (cores aleatórias).

Figure 3: <

4->Rótulos verdadeiros.

Consistência Semântica

95% dos clusters gerados eram "semanticamente puros".

Avaliação do Pré-processamento



Redução de Dimensionalidade

O pipeline reduziu o número de pontos em **98,84%**.

- Transforma uma nuvem com ~120.000 pontos em ~1.400 clusters.
- Redução massiva do custo computacional para a etapa de classificação.

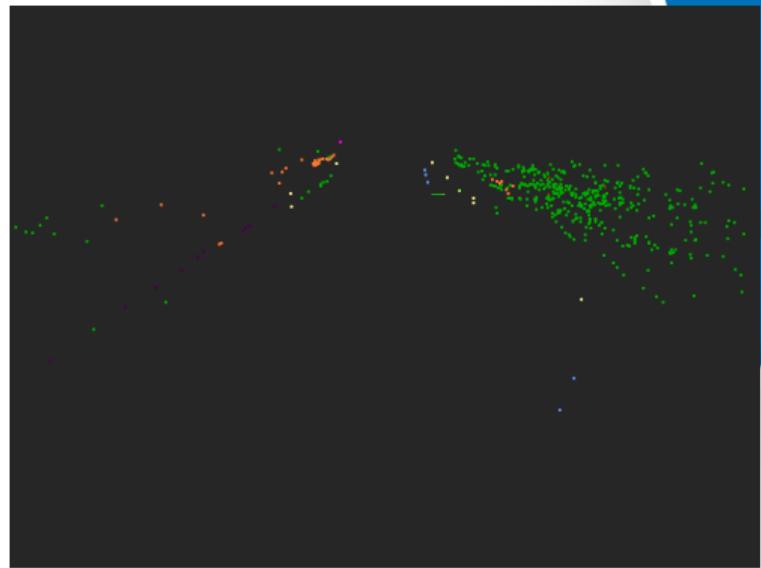


Figure 2: <

4->Clusters (cores aleatórias).

Consistência Semântica

95% dos clusters gerados eram "semanticamente puros".

Resultados da Classificação

- Após o pré-processamento, um vetor de características foi extraído para cada cluster.

Acurácia de Classificação

O modelo alcançou **93,27%** de acurácia na classificação dos clusters.

Figure 4: <

+>Matriz de confusão normalizada (exemplo).



Resultados da Classificação

- Após o pré-processamento, um vetor de características foi extraído para cada cluster.
- Uma rede PointNet simplificada foi usada para classificar cada cluster.

Acurácia de Classificação

O modelo alcançou **93,27%** de acurácia na classificação dos clusters.

Figure 4: <

+>Matriz de confusão normalizada (exemplo).



Resultados da Classificação

- Após o pré-processamento, um vetor de características foi extraído para cada cluster.
- Uma rede PointNet simplificada foi usada para classificar cada cluster.

Acurácia de Classificação

O modelo alcançou **93,27%** de acurácia na classificação dos clusters.

- **Conclusão:** A representação compacta em clusters, mesmo após uma redução de dados de >98%, reteve informação suficiente para uma classificação semântica de alta qualidade.

Figure 4: <

+>Matriz de confusão normalizada (exemplo).



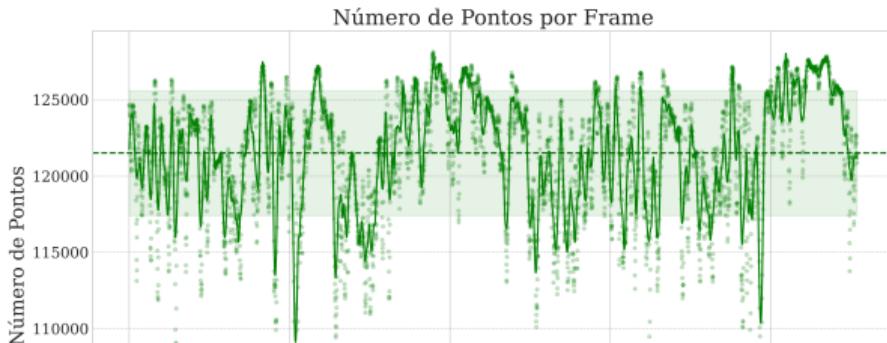
Resultados da Classificação

- Após o pré-processamento, um vetor de características foi extraído para cada cluster.
- Uma rede PointNet simplificada foi usada para classificar cada cluster.

Acurácia de Classificação

O modelo alcançou **93,27%** de acurácia na classificação dos clusters.

- **Conclusão:** A representação compacta em clusters, mesmo após uma redução de dados de >98%, reteve informação suficiente para uma classificação semântica de alta qualidade.





Conclusão e Trabalhos Futuros



Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.

Principal Contribuição

Demonstração de que é possível comprimir drasticamente nuvens de pontos LiDAR em representações de clusters, preservando a informação semântica essencial para a classificação.

Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.
- A abordagem demonstrou um excelente equilíbrio entre eficiência computacional e acurácia.

Principal Contribuição

Demonstração de que é possível comprimir drasticamente nuvens de pontos LiDAR em representações de clusters, preservando a informação semântica essencial para a classificação.

Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.
- A abordagem demonstrou um excelente equilíbrio entre eficiência computacional e acurácia.

Principal Contribuição

Demonstração de que é possível comprimir drasticamente nuvens de pontos LiDAR em representações de clusters, preservando a informação semântica essencial para a classificação.

- Os resultados (redução de 98.8%, acurácia de 93.3%) confirmam a viabilidade da metodologia para aplicações que demandam eficiência.

Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.

Trabalhos Futuros



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.

Trabalhos Futuros



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.

Trabalhos Futuros



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).
- Enriquecer as características dos clusters (e.g., intensidade, contexto).

Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).
- Enriquecer as características dos clusters (e.g., intensidade, contexto).
- Otimizar o pipeline para hardware embarcado.

Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).
- Enriquecer as características dos clusters (e.g., intensidade, contexto).
- Otimizar o pipeline para hardware embarcado.
- Validar em outras plataformas robóticas e com diferentes sensores.

Obrigado!

Perguntas?