

Segmentação Semântica de Nuvens de Pontos LiDAR

Uma Abordagem Híbrida Combinando Processamento Geométrico com Aprendizado Profundo

Matheus Leonel de Andrade¹

¹Instituto de Informática
Universidade Federal de Goiás

2025

Sumário



1. Introdução
2. Fundamentação Teórica
3. Metodologia
4. Resultados
5. Conclusão e Trabalhos Futuros



Introdução

Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).





Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).
- Nesse sentido os sensores LiDAR (Light Detection and Ranging) se destacam pois fornecem nuvens de pontos 3D, permitindo a análise detalhada da geometria do ambiente.



Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).
- Nesse sentido os sensores LiDAR (Light Detection and Ranging) se destacam pois fornecem nuvens de pontos 3D, permitindo a análise detalhada da geometria do ambiente.
- **Desafio:** Processar e interpretar o grande volume de dados das nuvens de pontos de forma eficiente, já que sensores LiDAR modernos podem capturar mais de 100.000 pontos por varredura.

Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.





Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam uma boa acurácia, mas exigem alto custo computacional.



Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam uma boa acurácia, mas exigem alto custo computacional.
- A segmentação do solo e a clusterização de objetos são etapas críticas e desafiadoras.

Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam uma boa acurácia, mas exigem alto custo computacional.
- A segmentação do solo e a clusterização de objetos são etapas críticas e desafiadoras.
 - A identificação do solo, serve como base para detecção de obstáculos, e planejamento de rotas, por exemplo.



Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam uma boa acurácia, mas exigem alto custo computacional.
- A segmentação do solo e a clusterização de objetos são etapas críticas e desafiadoras.
 - A identificação do solo, serve como base para detecção de obstáculos, e planejamento de rotas, por exemplo.
 - Da mesma forma, a clusterização e classificação de objetos, é fundamental para a tomada de decisões seguras em sistemas autônomo.

Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline para segmentação e classificação semântica de nuvens de pontos LiDAR.





Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline para segmentação e classificação semântica de nuvens de pontos LiDAR.
- **Abordagem Híbrida:** Combinar a eficiência de métodos clássicos de processamento geométrico com o poder de generalização de técnicas de aprendizado profundo.



Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline para segmentação e classificação semântica de nuvens de pontos LiDAR.
- **Abordagem Híbrida:** Combinar a eficiência de métodos clássicos de processamento geométrico com o poder de generalização de técnicas de aprendizado profundo.
- **Hipótese:** Investigar se a redução da dimensionalidade, através da clusterização, preserva informação semântica suficiente para uma classificação eficaz, equilibrando acurácia e custo computacional.



Fundamentação Teórica

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.

Segmentação e Clusterização

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.

Segmentação e Clusterização

- **Segmentação:** Atribuir um rótulo semântico a cada ponto (e.g., solo, carro, prédio).

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.

Segmentação e Clusterização

- **Segmentação:** Atribuir um rótulo semântico a cada ponto (e.g., solo, carro, prédio).
- **Clusterização:** Agrupar pontos próximos que pertencem ao mesmo objeto físico.

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Limitações Práticas

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Limitações Práticas

- Oclusões e dados incompletos

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Limitações Práticas

- Oclusões e dados incompletos
- Processamento em tempo real

Principais Desafios



Características dos Dados

- Irregularidade (sem estrutura de grade)
- Densidade variável com distância
- Grande volume de dados

Limitações Práticas

- Oclusões e dados incompletos
- Processamento em tempo real
- Generalização entre ambientes

Características dos Algoritmos Utilizados

- Ground Plane Fitting (GPF) - Segmentação do Solo:

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes
- **PointNet** - Classificação Semântica:

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes
- **PointNet** - Classificação Semântica:
 - Processa coordenadas 3D diretamente (sem projeção)

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes
- **PointNet** - Classificação Semântica:
 - Processa coordenadas 3D diretamente (sem projeção)
 - Invariante a permutações

Características dos Algoritmos Utilizados

- **Ground Plane Fitting (GPF)** - Segmentação do Solo:
 - Modela solo como plano estimado por SVD
 - Limitado a terrenos regulares
- **Scan Line Run (SLR)** - Clusterização:
 - Explora estrutura sequencial das scanlines LiDAR
 - Agrupa pontos por proximidade dentro de cada linha
 - Fusão de clusters entre scanlines adjacentes
- **PointNet** - Classificação Semântica:
 - Processa coordenadas 3D diretamente (sem projeção)
 - Invariante a permutações
 - T-Net para alinhamento espacial



Metodología

Pipeline Proposto



1. Nuvem de Pontos Bruta (Entrada)



2. Pré-processamento

2.1 GPF (Segmentação do Solo)



2.2 SLR (Clusterização)



2.3 Extração de Características



3. Classificação com PointNet (Saída)

Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em direção autônoma.



Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em direção autônoma.
- Extensão do KITTI Vision Benchmark.



Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em direção autônoma.
- Extensão do KITTI Vision Benchmark.
- Fornece anotações semânticas densas para nuvens de pontos capturadas por um LiDAR Velodyne HDL-64E.



Dataset: SemanticKITTI



- Benchmark de referência para percepção 3D em direção autônoma.
- Extensão do KITTI Vision Benchmark.
- Fornece anotações semânticas densas para nuvens de pontos capturadas por um LiDAR Velodyne HDL-64E.
- Foco do trabalho em 20 classes semânticas relevantes para navegação.

Dataset: SemanticKITTI

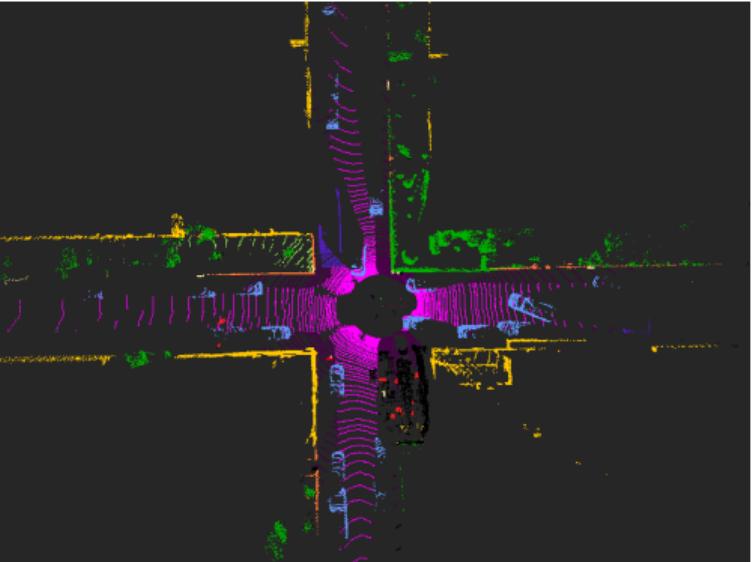


Figure 1: Exemplo de uma cena do SemanticKITTI com rótulos semânticos.
(sequencia 7 - frame 993)

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. Seleção dos pontos sementes.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. Seleção dos pontos sementes.
2. Estimativa do plano: calcula o LRP, em seguida aplica SVD para obter o vetor normal do plano.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. Seleção dos pontos sementes.
2. Estimativa do plano: calcula o LRP, em seguida aplica SVD para obter o vetor normal do plano.
3. Refinamento iterativo: inclui pontos próximos do plano (< limiar) em iterações sucessivas, e repete o item 2.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. Seleção dos pontos sementes.
2. Estimativa do plano: calcula o LRP, em seguida aplica SVD para obter o vetor normal do plano.
3. Refinamento iterativo: inclui pontos próximos do plano (< limiar) em iterações sucessivas, e repete o item 2.
4. Classificação final: pontos do solo recebem label específico.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.
2. Identificação de "runs": segmentos contínuos com distância < limiar.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.
2. Identificação de "runs": segmentos contínuos com distância < limiar.
3. Propagação de rótulos entre scanlines adjacentes (< limiar).

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.
2. Identificação de "runs": segmentos contínuos com distância < limiar.
3. Propagação de rótulos entre scanlines adjacentes (< limiar).
4. Resolução de equivalências via tabela para fundir rótulos duplicados.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Agrupamento inicial por scanline preservando estrutura sequencial LiDAR.
2. Identificação de "runs": segmentos contínuos com distância < limiar.
3. Propagação de rótulos entre scanlines adjacentes (< limiar).
4. Resolução de equivalências via tabela para fundir rótulos duplicados.
5. Atribuição final: cada cluster recebe identificador único.

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)
 - Capturam forma e orientação do cluster

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)
 - Capturam forma e orientação do cluster
- Rótulos (2 valores):

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)
 - Capturam forma e orientação do cluster
- Rótulos (2 valores):
 - True label (anotação ground truth)

Pré-processamento: Extração de Características



Objetivo

Extrair vetor de características para cada cluster gerado pelo SLR.

Saída

Vetor de 24 características + 2 rótulos por cluster.

Características Extraídas

- Posição espacial (9 valores):
 - Centroide (x, y, z) - posição central
 - Bounding box: pontos mín/máx (x, y, z)
- Distribuição espacial (15 valores):
 - Histogramas X, Y, Z (5 bins cada)
 - Capturam forma e orientação do cluster
- Rótulos (2 valores):
 - True label (anotação ground truth)
 - Predicted label (placeholder para classificação)

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Modificações Implementadas

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Modificações Implementadas

- Expansão da capacidade:

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Modificações Implementadas

- Expansão da capacidade:
 - Maior largura (mais canais)

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Modificações Implementadas

- Expansão da capacidade:
 - Maior largura (mais canais)
 - Maior profundidade (mais camadas)

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Modificações Implementadas

- Expansão da capacidade:
 - Maior largura (mais canais)
 - Maior profundidade (mais camadas)
 - compensar a redução da dimensionalidade

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Modificações Implementadas

- Expansão da capacidade:
 - Maior largura (mais canais)
 - Maior profundidade (mais camadas)
 - compensar a redução da dimensionalidade
 - Redução significativa na dimensionalidade mitiga custo computacional da expansão do modelo.

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Modificações Implementadas

- Expansão da capacidade:
 - Maior largura (mais canais)
 - Maior profundidade (mais camadas)
 - compensar a redução da dimensionalidade
 - Redução significativa na dimensionalidade mitiga custo computacional da expansão do modelo.
- Adaptação da entrada para aceitar as 24 características

Classificação: PointNet Modificada



Entrada

Vetores de 24 características

Saida

Clusters classificados em 20 categorias semânticas.

Modificações Implementadas

- Expansão da capacidade:
 - Maior largura (mais canais)
 - Maior profundidade (mais camadas)
 - compensar a redução da dimensionalidade
 - Redução significativa na dimensionalidade mitiga custo computacional da expansão do modelo.
- Adaptação da entrada para aceitar as 24 características
- Normalização atualizada de BatchNorm para InstanceNorm1d



Resultados

Saída do GPF

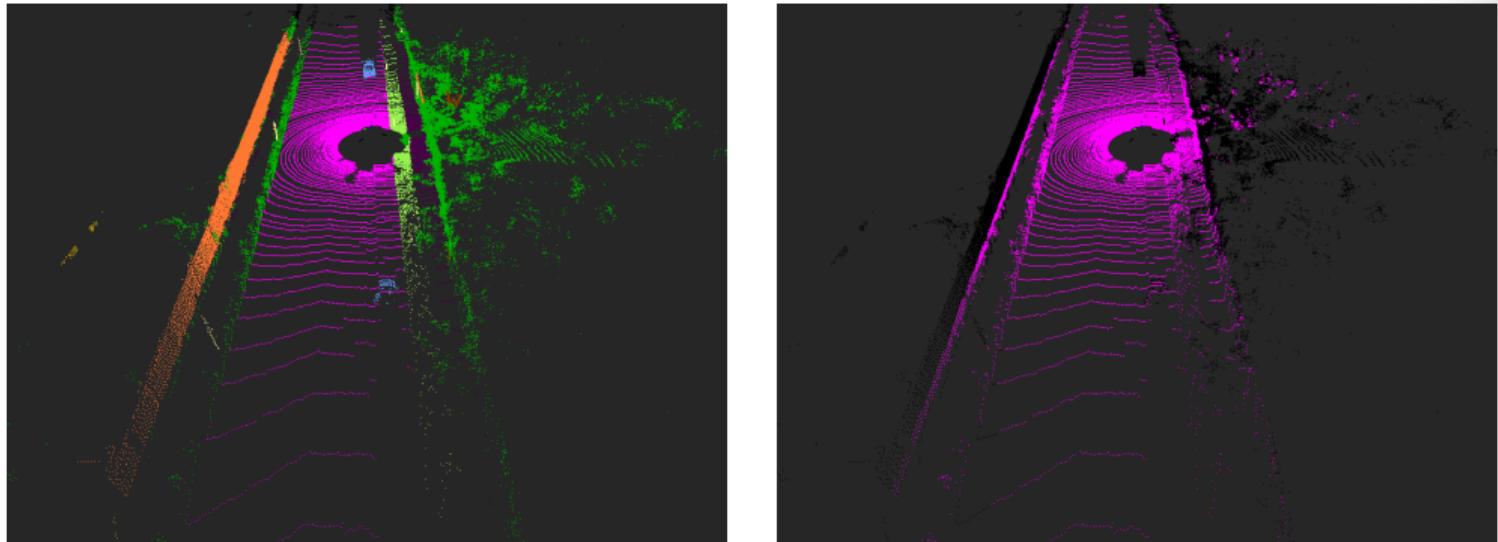


Figure 2: Comparação entre rótulos reais (esquerda) segmentação predita pelo GPF (direita), sequencia 4 - frame 75.

Analise dos Clusters Inconsistentes

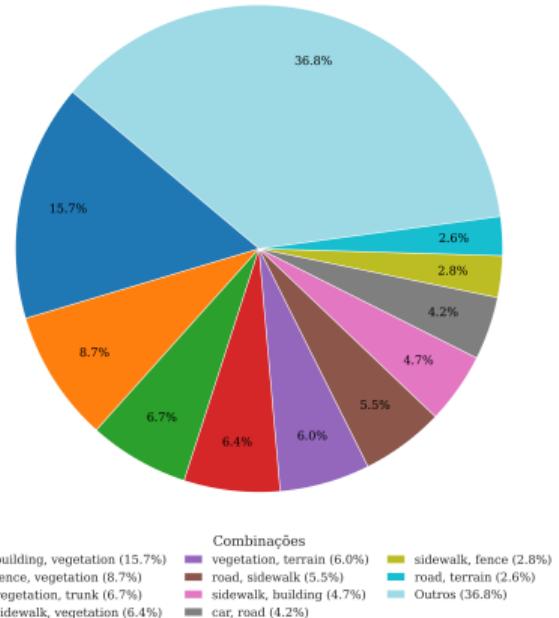


Figure 3: Combinações mais frequentes dos clusters inconsistentes, sequencia 0.

Saida do SLR

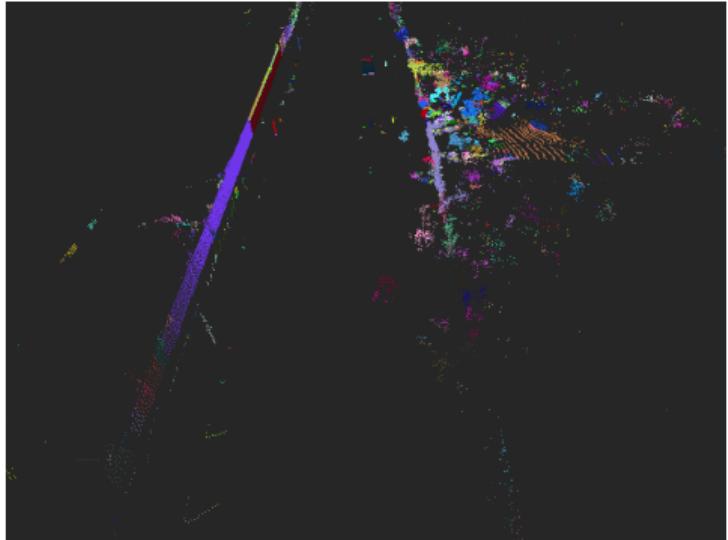


Figure 4: Saida do SLR, sequencia 4 - frame 75.

Analise dos Clusters Inconsistentes

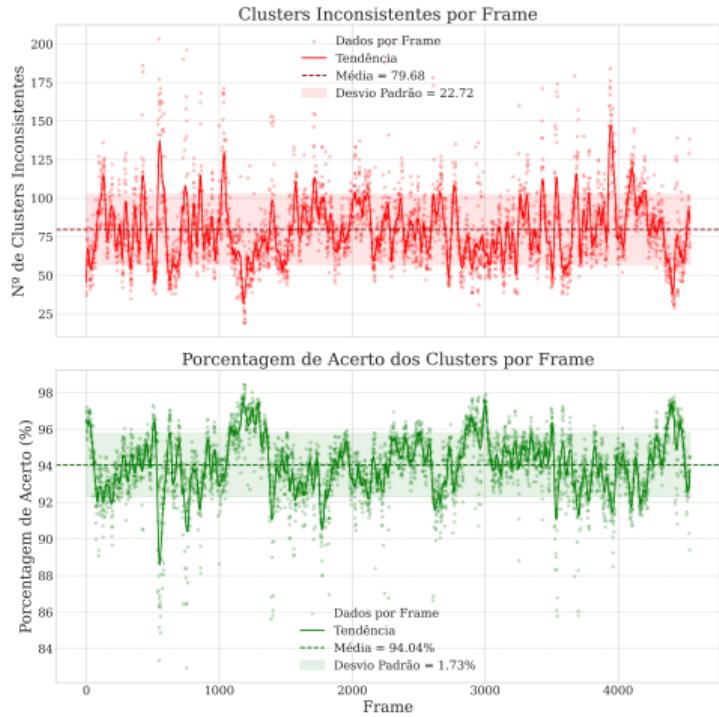


Figure 5: Gráfico de analise dos clusters inconsistentes, sequencia 0.

Clusters após Extração de Características

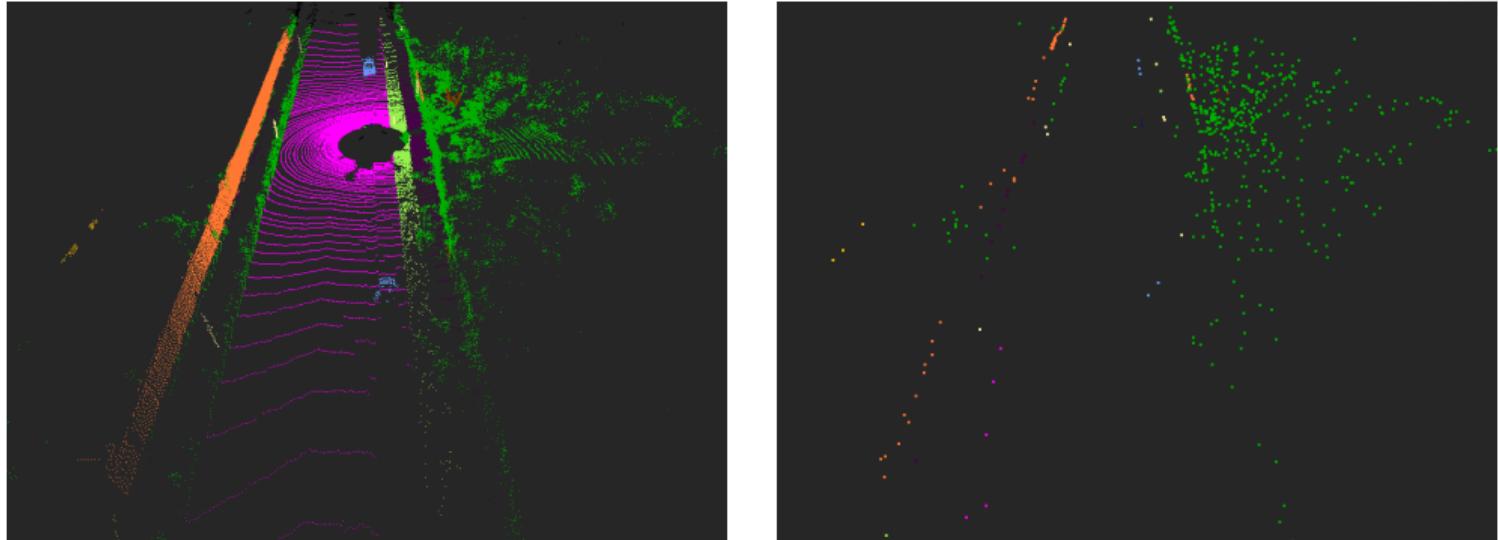


Figure 6: Comparação dos dados originais (esquerda) com os clusters após extração de características (direita), sequencia 4 - frame 75.

Avaliação da Redução de Dimensionalidade

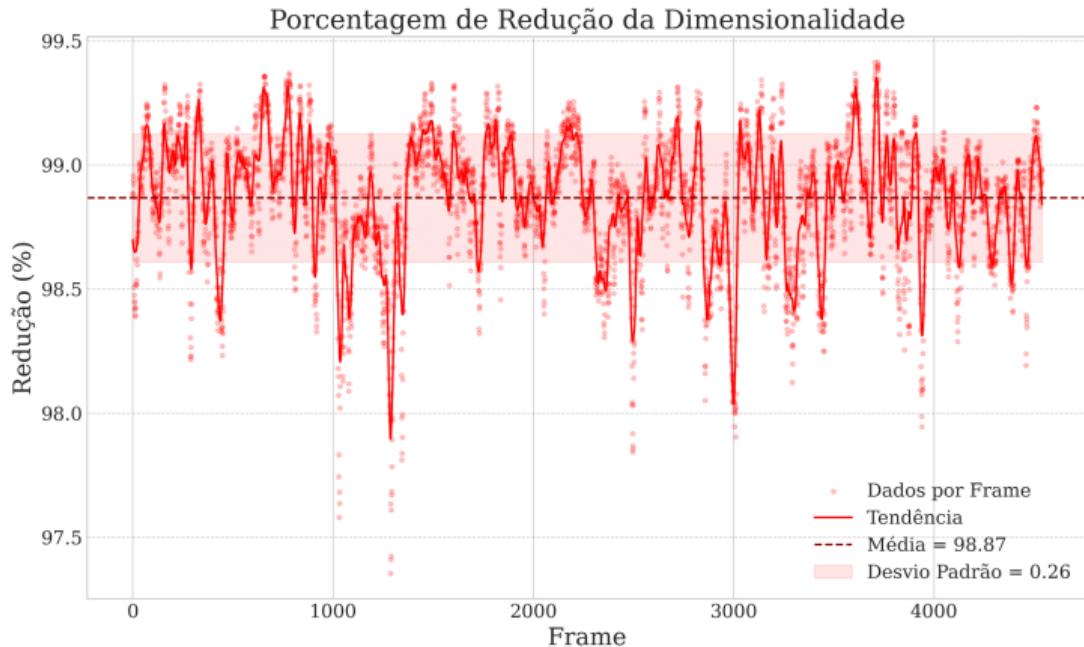


Figure 7: Gráfico de análise da redução de dimensionalidade, sequencia 0.

Classificação

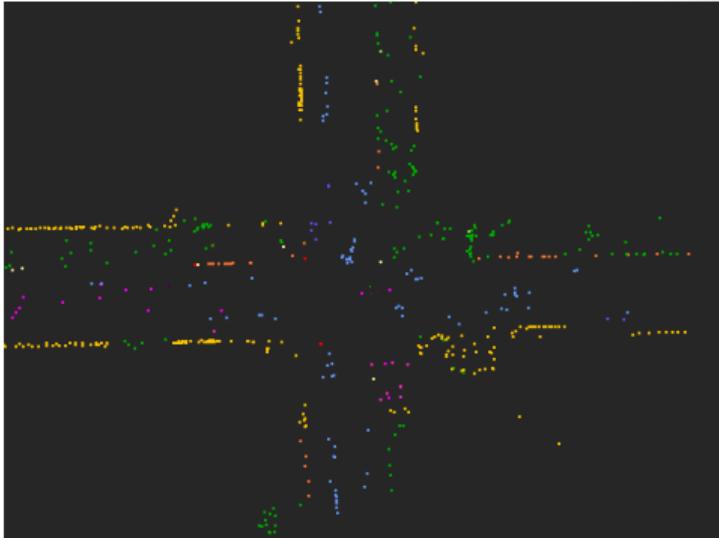
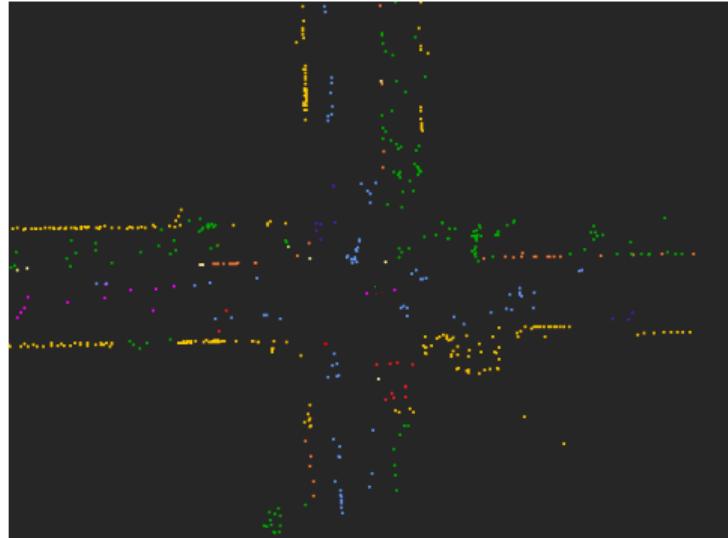


Figure 8: Comparação entre cluster obtidos (esquerda) com a classificação do modelo (direita), sequencia 7 - frame 993.

Desempenho do Modelo

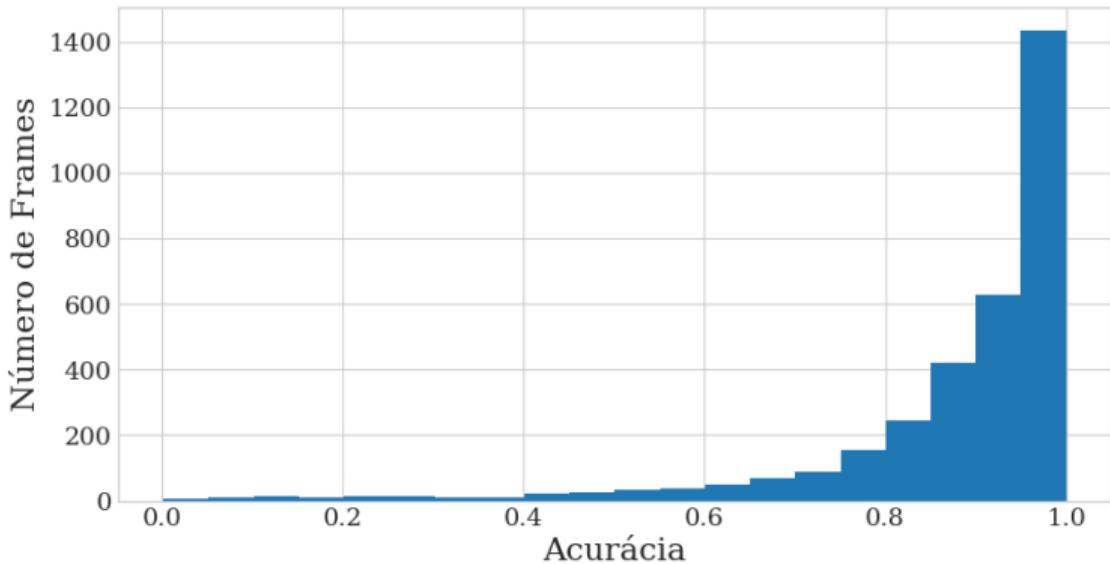


Figure 9: Gráfico da distribuição de acu, sequencia 0.



Conclusão e Trabalhos Futuros

Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.



Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.
- Os resultados (redução de 98.8%, acurácia de 93.3%) confirmam a viabilidade da metodologia.



Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.
- Os resultados (redução de 98.8%, acurácia de 93.3%) confirmam a viabilidade da metodologia.

Principal Contribuição

Demonstração de que é possível comprimir drasticamente nuvens de pontos LiDAR em representações de clusters, preservando a informação semântica essencial para a classificação.

Limitações e Trabalhos Futuros

Limitações



Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos

Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos
- **Generalização limitada:** validação restrita ao SemanticKITTI

Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos
- **Generalização limitada:** validação restrita ao SemanticKITTI
- **Classes minoritárias:** desempenho inferior em objetos menos representados

Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos
- **Generalização limitada:** validação restrita ao SemanticKITTI
- **Classes minoritárias:** desempenho inferior em objetos menos representados
- **Método fixo:** GPF tem dificuldades com terrenos irregulares por ser um modelo geométrico fixo.

Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos
- **Generalização limitada:** validação restrita ao SemanticKITTI
- **Classes minoritárias:** desempenho inferior em objetos menos representados
- **Método fixo:** GPF tem dificuldades com terrenos irregulares por ser um modelo geométrico fixo.

Trabalhos Futuros

Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos
- **Generalização limitada:** validação restrita ao SemanticKITTI
- **Classes minoritárias:** desempenho inferior em objetos menos representados
- **Método fixo:** GPF tem dificuldades com terrenos irregulares por ser um modelo geométrico fixo.

Trabalhos Futuros

- **Robustez:** métodos de segmentação mais flexíveis e resilientes

Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos
- **Generalização limitada:** validação restrita ao SemanticKITTI
- **Classes minoritárias:** desempenho inferior em objetos menos representados
- **Método fixo:** GPF tem dificuldades com terrenos irregulares por ser um modelo geométrico fixo.

Trabalhos Futuros

- **Robustez:** métodos de segmentação mais flexíveis e resilientes
- **Enriquecimento:** Como incluir intensidade LiDAR e outros dados contextuais

Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos
- **Generalização limitada:** validação restrita ao SemanticKITTI
- **Classes minoritárias:** desempenho inferior em objetos menos representados
- **Método fixo:** GPF tem dificuldades com terrenos irregulares por ser um modelo geométrico fixo.

Trabalhos Futuros

- **Robustez:** métodos de segmentação mais flexíveis e resilientes
- **Enriquecimento:** Como incluir intensidade LiDAR e outros dados contextuais
- **Generalização:** validar em múltiplos datasets e sensores

Limitações e Trabalhos Futuros



Limitações

- **Fragmentação:** clusterização geométrica pode dividir objetos complexos
- **Generalização limitada:** validação restrita ao SemanticKITTI
- **Classes minoritárias:** desempenho inferior em objetos menos representados
- **Método fixo:** GPF tem dificuldades com terrenos irregulares por ser um modelo geométrico fixo.

Trabalhos Futuros

- **Robustez:** métodos de segmentação mais flexíveis e resilientes
- **Enriquecimento:** Como incluir intensidade LiDAR e outros dados contextuais
- **Generalização:** validar em múltiplos datasets e sensores
- **Eficiência:** otimização do pipeline

Obrigado!
Duvidas ou Sugestões?
matheus.leonel@discente.ufg.com

