

Segmentação Semântica de Nuvens de Pontos LiDAR

Uma Abordagem Híbrida Combinando Processamento Geométrico com Aprendizado Profundo

Matheus Leonel de Andrade¹

¹Instituto de Informática
Universidade Federal de Goiás

2025

Roteiro



1. Introdução
2. Fundamentação Teórica
3. Metodologia
4. Resultados
5. Conclusão e Trabalhos Futuros



Introdução

Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).





Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).
- Sensores LiDAR (Light Detection and Ranging) são essenciais, fornecendo nuvens de pontos 3D densas e precisas.



Motivação

- A percepção 3D do ambiente é um pilar fundamental para sistemas autônomos (veículos autônomos, robótica móvel).
- Sensores LiDAR (Light Detection and Ranging) são essenciais, fornecendo nuvens de pontos 3D densas e precisas.
- **Desafio:** Processar e interpretar o grande volume de dados das nuvens de pontos (alta dimensionalidade, esparsas, desordenadas) de forma eficiente.

Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.





Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam alta acurácia, mas exigem alto custo computacional, dificultando o uso em sistemas com recursos limitados.



Problema de Pesquisa

- Algoritmos de segmentação e classificação de nuvens de pontos ainda possuem limitações em robustez, escalabilidade e generalização.
- Abordagens baseadas em Deep Learning (e.g., PointNet, KPConv) alcançam alta acurácia, mas exigem alto custo computacional, dificultando o uso em sistemas com recursos limitados.
- A segmentação do solo e a clusterização de objetos são etapas críticas e desafiadoras.

Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline eficiente para segmentação e classificação semântica de nuvens de pontos LiDAR.





Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline eficiente para segmentação e classificação semântica de nuvens de pontos LiDAR.
- **Abordagem Híbrida:** Combinar a eficiência de métodos clássicos de processamento geométrico com o poder de generalização de técnicas de aprendizado profundo.



Objetivos

- **Objetivo Principal:** Desenvolver e avaliar um pipeline eficiente para segmentação e classificação semântica de nuvens de pontos LiDAR.
- **Abordagem Híbrida:** Combinar a eficiência de métodos clássicos de processamento geométrico com o poder de generalização de técnicas de aprendizado profundo.
- **Hipótese:** Investigar se a redução da dimensionalidade, através da clusterização, preserva informação semântica suficiente para uma classificação eficaz, equilibrando acurácia e custo computacional.



Fundamentação Teórica

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).

Segmentação e Clusterização

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.

Segmentação e Clusterização

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.

Segmentação e Clusterização

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.
- LiDAR gera padrão de "scanlines".

Segmentação e Clusterização

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.
- LiDAR gera padrão de "scanlines".

Segmentação e Clusterização

- **Segmentação:** Atribuir um rótulo semântico a cada ponto (e.g., solo, carro, prédio).

Conceitos Fundamentais



Nuvens de Pontos 3D

- Conjunto de pontos com coordenadas (x, y, z).
- Representação direta da geometria da cena.
- Dados não estruturados, esparsos e com densidade variável.
- LiDAR gera padrão de "scanlines".

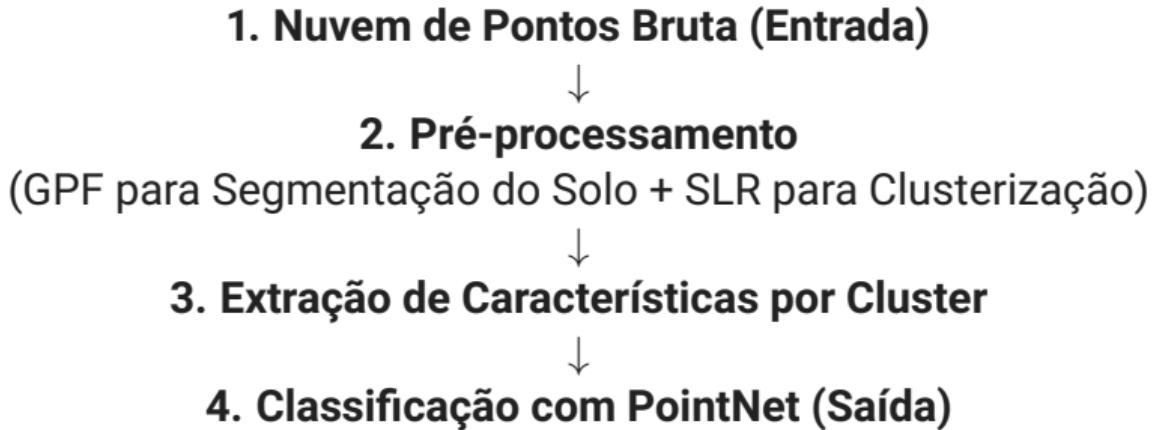
Segmentação e Clusterização

- **Segmentação:** Atribuir um rótulo semântico a cada ponto (e.g., solo, carro, prédio).
- **Clusterização:** Agrupar pontos próximos que pertencem ao mesmo objeto físico.



Metodología

Pipeline Proposto



Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em condução autônoma.





Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em condução autônoma.
- Extensão semântica do KITTI Vision Benchmark.



Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em condução autônoma.
- Extensão semântica do KITTI Vision Benchmark.
- Fornece anotações semânticas densas para nuvens de pontos capturadas por um LiDAR Velodyne HDL-64E.



Dataset: SemanticKITTI

- Benchmark de referência para percepção 3D em condução autônoma.
- Extensão semântica do KITTI Vision Benchmark.
- Fornece anotações semânticas densas para nuvens de pontos capturadas por um LiDAR Velodyne HDL-64E.
- Foco do trabalho em 20 classes semânticas relevantes para navegação.

Dataset: SemanticKITTI

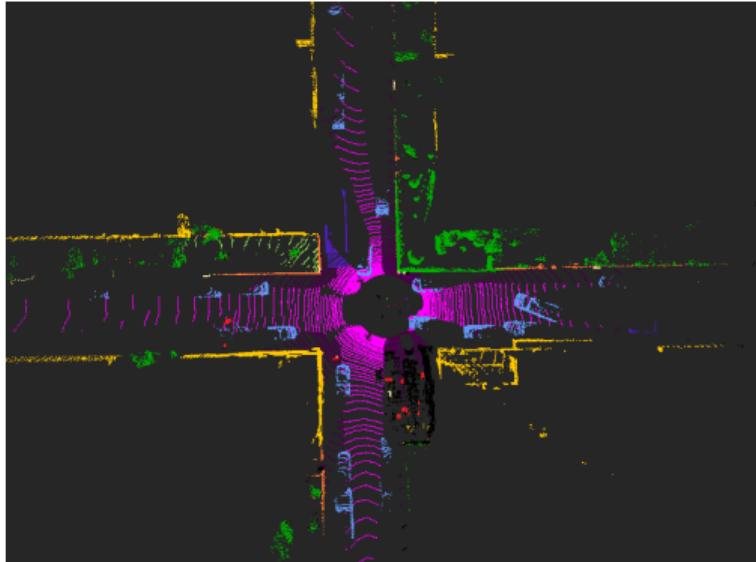


Figure 1: Exemplo de uma cena do SemanticKITTI com rótulos semânticos.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar e remover os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. A nuvem de pontos é dividida em setores angulares.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar e remover os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. A nuvem de pontos é dividida em setores angulares.
2. Em cada setor, o solo é modelado como um plano.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar e remover os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. A nuvem de pontos é dividida em setores angulares.
2. Em cada setor, o solo é modelado como um plano.
3. O plano é estimado de forma iterativa usando SVD sobre os pontos de menor altura.

Pré-processamento: Segmentação do Solo (GPF)



Objetivo

Identificar e remover os pontos pertencentes ao solo.

Algoritmo

Ground Plane Fitting (GPF).

Como funciona

1. A nuvem de pontos é dividida em setores angulares.
2. Em cada setor, o solo é modelado como um plano.
3. O plano é estimado de forma iterativa usando SVD sobre os pontos de menor altura.
4. Pontos próximos ao plano estimado são classificados como solo.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Explora a estrutura sequencial das scanlines do LiDAR.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Explora a estrutura sequencial das scanlines do LiDAR.
2. Pontos em uma mesma scanline são agrupados com base na proximidade.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Explora a estrutura sequencial das scanlines do LiDAR.
2. Pontos em uma mesma scanline são agrupados com base na proximidade.
3. Clusters de scanlines adjacentes são fundidos se estiverem próximos.

Pré-processamento: Clusterização de Objetos (SLR)



Objetivo

Agrupar os pontos remanescentes (não-solo) em clusters que representam objetos.

Algoritmo

Scan Line Run (SLR).

Como funciona

1. Explora a estrutura sequencial das scanlines do LiDAR.
2. Pontos em uma mesma scanline são agrupados com base na proximidade.
3. Clusters de scanlines adjacentes são fundidos se estiverem próximos.
4. Resultado: Uma lista de clusters, cada um representando um potencial objeto.



Resultados

Avaliação do Pré-processamento



Redução de Dimensionalidade

O pipeline reduziu o número de pontos em **98,84%**.

Figure 2: <

4->Clusters (cores aleatórias).

Figure 3: <

4->Rótulos verdadeiros.

Consistência Semântica

95% dos clusters gerados eram "semanticamente puros".

Avaliação do Pré-processamento



Redução de Dimensionalidade

O pipeline reduziu o número de pontos em **98,84%**.

- Transforma uma nuvem com ~120.000 pontos em ~1.400 clusters.
- Redução massiva do custo computacional para a etapa de classificação.

Figure 2: <

4->Clusters (cores aleatórias).

Figure 3: <

4->Rótulos verdadeiros.

Consistência Semântica

95% dos clusters gerados eram "semanticamente puros".

Avaliação do Pré-processamento



Redução de Dimensionalidade

O pipeline reduziu o número de pontos em **98,84%**.

- Transforma uma nuvem com ~120.000 pontos em ~1.400 clusters.
- Redução massiva do custo computacional para a etapa de classificação.

Figure 2: <

4->Clusters (cores aleatórias).

Figure 3: <

4->Rótulos verdadeiros.

Consistência Semântica

95% dos clusters gerados eram "semanticamente puros".

Avaliação do Pré-processamento



Redução de Dimensionalidade

O pipeline reduziu o número de pontos em **98,84%**.

- Transforma uma nuvem com ~120.000 pontos em ~1.400 clusters.
- Redução massiva do custo computacional para a etapa de classificação.

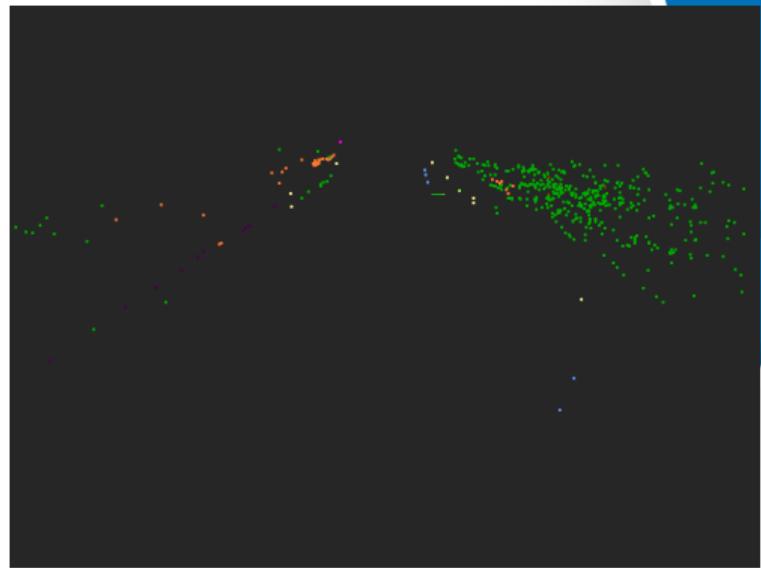


Figure 2: <

4->Clusters (cores aleatórias).

Consistência Semântica

95% dos clusters gerados eram "semanticamente puros".

Resultados da Classificação

- Após o pré-processamento, um vetor de características foi extraído para cada cluster.

Acurácia de Classificação

O modelo alcançou **93,27%** de acurácia na classificação dos clusters.

Figure 4: <

+>Matriz de confusão normalizada (exemplo).



Resultados da Classificação

- Após o pré-processamento, um vetor de características foi extraído para cada cluster.
- Uma rede PointNet simplificada foi usada para classificar cada cluster.

Acurácia de Classificação

O modelo alcançou **93,27%** de acurácia na classificação dos clusters.

Figure 4: <

+>Matriz de confusão normalizada (exemplo).



Resultados da Classificação

- Após o pré-processamento, um vetor de características foi extraído para cada cluster.
- Uma rede PointNet simplificada foi usada para classificar cada cluster.

Acurácia de Classificação

O modelo alcançou **93,27%** de acurácia na classificação dos clusters.

- **Conclusão:** A representação compacta em clusters, mesmo após uma redução de dados de >98%, reteve informação suficiente para uma classificação semântica de alta qualidade.

Figure 4: <

+>Matriz de confusão normalizada (exemplo).

Resultados da Classificação

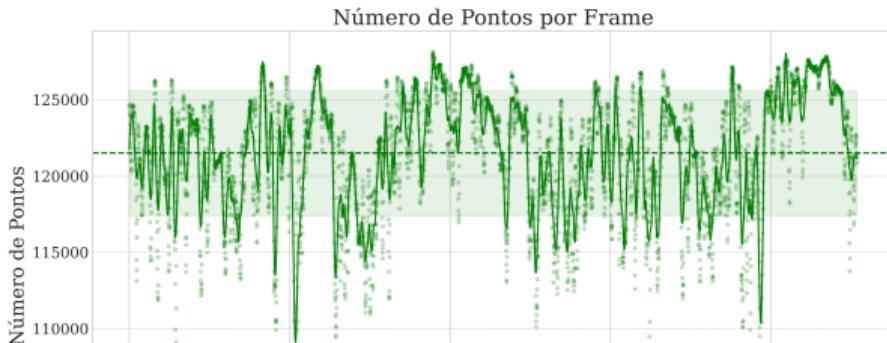


- Após o pré-processamento, um vetor de características foi extraído para cada cluster.
 - Uma rede PointNet simplificada foi usada para classificar cada cluster.

Acurácia de Classificação

O modelo alcançou **93,27%** de acurácia na classificação dos clusters.

- **Conclusão:** A representação compacta em clusters, mesmo após uma redução de dados de >98%, reteve informação suficiente para uma classificação semântica de alta qualidade.





Conclusão e Trabalhos Futuros



Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.

Principal Contribuição

Demonstração de que é possível comprimir drasticamente nuvens de pontos LiDAR em representações de clusters, preservando a informação semântica essencial para a classificação.

Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.
- A abordagem demonstrou um excelente equilíbrio entre eficiência computacional e acurácia.

Principal Contribuição

Demonstração de que é possível comprimir drasticamente nuvens de pontos LiDAR em representações de clusters, preservando a informação semântica essencial para a classificação.

Conclusões

- O trabalho validou um pipeline híbrido que combina processamento geométrico clássico com aprendizado profundo para segmentação semântica de nuvens de pontos.
- A abordagem demonstrou um excelente equilíbrio entre eficiência computacional e acurácia.

Principal Contribuição

Demonstração de que é possível comprimir drasticamente nuvens de pontos LiDAR em representações de clusters, preservando a informação semântica essencial para a classificação.

- Os resultados (redução de 98.8%, acurácia de 93.3%) confirmam a viabilidade da metodologia para aplicações que demandam eficiência.

Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.

Trabalhos Futuros



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.

Trabalhos Futuros



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.

Trabalhos Futuros



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).



Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).
- Enriquecer as características dos clusters (e.g., intensidade, contexto).

Limitações e Trabalhos Futuros

Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).
- Enriquecer as características dos clusters (e.g., intensidade, contexto).
- Otimizar o pipeline para hardware embarcado.

Limitações e Trabalhos Futuros



Limitações

- Propagação de erros: falhas na segmentação do solo afetam a clusterização e classificação.
- A clusterização pode fragmentar objetos grandes ou complexos.
- Validação restrita ao dataset SemanticKITTI.
- Implementação não otimizada para tempo real.

Trabalhos Futuros

- Aprimorar a segmentação do solo (modelos mais flexíveis).
- Enriquecer as características dos clusters (e.g., intensidade, contexto).
- Otimizar o pipeline para hardware embarcado.
- Validar em outras plataformas robóticas e com diferentes sensores.

Obrigado!

Perguntas?